

# Проверка статистических гипотез

---

Часть 3

Аббакумов Вадим Леонардович

Версия 4

# Раздел 3

## Популярные статистические критерии

# Гипотеза о нормальности распределения случайной величины

- **Гипотеза:** Случайная величина имеет нормальное распределение, значения параметров распределения могут быть любыми.
- **Конкурирующая гипотеза:** Распределение случайной величины отличается от нормального.

---

# Литература

Thode

Testing For Normality

CRC Press 2002 368с

Не дает рекомендаций по выбору критерия.

---

---

# Критерий Шапиро-Уилка

- Критерий Шапиро-Уилка
  - `scipy.stats.shapiro`    # В Python
  - `shapiro.test(data)`    # В R
-

---

# Другие критерии в Python

Критерий Anderson-Darling

`scipy.stats.anderson`

Критерий Lilliefors (Kolmogorov-Smirnov)

`statsmodels.stats.diagnostic.lilliefors`

---

---

# В языке R пакет "nortest"

Критерий Anderson-Darling

`ad.test(data)`

Критерий Lilliefors (Kolmogorov-Smirnov)

`lillie.test(x)`

---

# Число наблюдений

Если меньше 2000 (?) наблюдений,  
рекомендуется использовать критерий  
Шапиро-Уилка

если больше 2000 (?), то критерий  
Колмогорова-Смирнова.



# А нужно ли проверять гипотезу нормальности?

- Методы, которые рассматриваются в курсе далее, работают когда
  - переменная имеет нормальное распределение
  - распределение несущественно отличается от нормального

# гипотеза о нормальности распределения переменной отвергнута

- Некоторые отклонения от нормальности существенные.
- Некоторые отклонения от нормальности несущественные.


# Существенные отклонения

1. Наличие выбросов в данных.
2. Явная асимметрия гистограммы.
3. Очень сильное отклонение формы гистограммы от колоколообразной формы.


# Рекомендуется относиться

- Строго - к присутствию выбросов,
- Снисходительно - к отклонениям от симметрии.
- Отношение к колоколообразной форме гистограммы зависит от числа наблюдений. Если меньше 30 наблюдений, наше отношение в высшей степени либерально, если число наблюдений находится между 30 и 150, мы относимся к отклонениям снисходительно, если имеется больше 150 наблюдений – строго.


## Histogram



## Histogram



## Histogram



# Лекарства

Иногда они опаснее болезни...

Выбросы — удаляем (осторожно!)

Асимметрия — преобразуем данные (например, логарифмируем, или преобразование Бокса-Кокса)

Бимодальность — разбиваем выборку на подвыборки



# Пример 1

- Население городов России в 1959 году
- Исходные данные
- Логарифм населения

---

## Пример 2

- Альбукерк – продажи домов

---

# Гипотезы о типичных наблюдениях (о центрах распределений)

---

# Сравнение центров распределений

- *Центр распределения* - то одно единственное число, которое описывает, характеризует выборку.
- В качестве центра чаще всего используют среднее арифметическое, медиану или усеченное среднее.
- Центр распределения и типичное наблюдение синонимы

# Среднее или медиана?

- у человека в среднем меньше двух глаз
- $x1 \leftarrow c(1, 1, 1, 1000, 1000)$   
 $x2 \leftarrow c(2, 3, 4, 5, 6)$   
Доходы  $x1$  выше,  $x2$  прибыльнее чаще

---

# Другие методы оценки центра распределения

Andrews; Bickel; Hampel; Huber; Rogers,  
Tukey.

Robust estimates of location: survey and  
advances.

1972 Princeton University Press

---

# Среднее арифметическое или медиана?

- Если распределение хотя бы одной из выборок существенно отличается от нормального, в качестве центра предлагается использовать медиану.
- В остальных случаях, то есть если распределение каждой выборки можно считать нормальным или несущественно отличающимся от нормального, в качестве центра предлагается использовать среднее арифметическое.

# Выбор центра распределения

- Если центр распределения медиана, используем критерий Манна – Уитни-Вилкоксона или (редко) Mood's median критерий .
- Если центр распределения среднее арифметическое, используем одну из версий критерия Стьюдента.



# Прагматичный подход

Применить оба теста.

Если выводы совпадают, ответ есть

Если выводы различны, начинаем  
разбираться.

# Парные выборки

- В случае парных выборок имеются пары наблюдений (измерений) одного и того же объекта.
- Например: пары измерений делались в один и тот же момент.
- Например: два измерения одной переменной делались последовательно.

# Независимые выборки

- В случае *независимых выборок* каждое наблюдение соответствует отдельному объекту, измеряются разные объекты.

Принадлежность объектов выборкам определяется по значениям дополнительной группирующей переменной.

# В языке R и Python

## Независимые и парные выборки

- В питоне используем разные версии критериев
- Если выборки парные, используется опция `paired = TRUE`.
- Если выборки независимые, используется опция `paired = FALSE`.

# Сравнение средних значений выборок

- $H_0$ : Математические ожидания равны.
  - $EX = EY$
- $H_1$ : Математические ожидания различны.
  - $EX \neq EY$

# T-критерий Стьюдента

## В Python

`scipy.stats.ttest_ind`

`scipy.stats.ttest_rel`

## В R

`t.test(x, y, alternative = "two.sided",  
paired = FALSE, var.equal = FALSE)`

# Надо еще сравнить дисперсии - 1

Метод 1 — устарел, но еще встречается

F-test of equality of variances

Не рекомендуется, слишком чувствителен к отклонениям от нормальности. См.

[http://en.wikipedia.org/wiki/F-test\\_of\\_equality\\_of\\_variances](http://en.wikipedia.org/wiki/F-test_of_equality_of_variances)

В R

`var.test(x, y)`

## Надо еще сравнить дисперсии - 2

Метод 2 — устарел, но еще встречается

Bartlett's test

Если данные нормально распределены,  
лучший вариант.

**Не рекомендуется:** чувствителен к  
отклонениям от нормальности;

Если данные не нормальны, часто дает  
"false positive" результат.



# Надо еще сравнить дисперсии - 2

## Метод 2

### Bartlett's test

В R

```
bartlett.test(x, g, data=data.table)
```

```
bartlett.test(x~g, data=data.table)
```

# Надо еще сравнить дисперсии - 3

- Метод 3— устарел, но еще встречается
- Levene's test
- Критерий Ливиня/Левена

# Надо еще сравнить дисперсии - 3

- В R Levene's test

```
library(car)
```

```
leveneTest(x~g, data=data.table)
```

---

Надо еще сравнить дисперсии - 4

Fligner-Killeen test

Робастный, **рекомендуется.**

возможно Brown-Forsythe test еще лучше...

---

# Надо еще сравнить дисперсии - 4

В Python

```
scipy.stats.fligner
```

В R

```
fligner.test(x~g, data=data.table)
```

---

# Можно поступать лучше, но нельзя

В. В. Славова, Д. М. Чибисов, “О  
предварительном тестировании в задаче  
Беренса–Фишера”, Обозрение прикладной  
и промышленной математики, 16:2 (2009),  
210–225

---

---

# Если данные существенно отклоняются от нормальности

Но нужно сравнить средние

1. Все как в случае нормальности, если выборка большая ( $n > 300$ )
  2. Преобразовать данные к нормальному виду
-

---

# Анализ мощности

Можно начать изучение со статьи

A Gentle Introduction to Statistical Power and  
Power Analysis in Python

<https://machinelearningmastery.com/statistical-power-and-power-analysis-in-python/>

---



# Сравнение медиан выборок

$H_0$ : Медианы равны

$H_1$ : Медианы различаются

# Mood's median test in R

```
m <- median(c(x1,x2))    # joint median
f11 <- sum(x1>m)          # Pop.1 samples above median
f12 <- sum(x2>m)
f21 <- sum(x1<=m)        # Pop.1 samples below or at
  median
f22 <- sum(x2<=m)
# 2x2 contingency table
table <- matrix(c(f11,f12,f21,f22), nrow=2,ncol=2)
chisq.test(table)
```

---

# Mood's median test в Python

`scipy.stats.median_test`

---

---

# Mood's median test

Friedlin, B. & Gastwirth, J. L. (2000).

Should the median test be retired from general use?

The American Statistician, 54, 161–164.

Не рекомендуют. Большая ошибка 2 рода для малых выборок (по сравнению с другими тестами)

Можно применять только для больших выборок 3000+ наблюдений

---

---

# Критерий Манна-Уитни

Mann-Whitney U-test

Mann–Whitney–Wilcoxon,

Wilcoxon rank-sum test,

Wilcoxon–Mann–Whitney test

---

# Важно!

- Критерий Манна-Уитни на самом деле проверяет другую гипотезу.
- Имеются две выборки наблюдений случайных величин  $X$  и  $Y$ .
- $H_0: P\{X>Y\}=P\{X<Y\}$ .
- $H_1: P\{X>Y\} \neq P\{X<Y\}$ .

---

Goos, Meintrup

## Statistics with JMP: Hypothesis Tests, Anova and Regression 2016

### 9 A Nonparametric Hypothesis Test for the Medians of Two Independent Samples

... The recommended test in that case is the Wilcoxon rank-sum test. ...  
The Wilcoxon rank-sum test is also called the Mann–Whitney U-test.

#### 9.1 The Hypotheses Tested

The rank-sum test is designed to determine whether the medians of two populations are equal. The test's null hypothesis is

$$H_0: \text{Med } 1 = \text{Med } 2$$

where Med 1 and Med 2 represent the medians of the first population and the second population, respectively.

---

---

Критерий Манна-Уитни не учитывает  
величины наблюдений, а только их ранги

---



# Статистика критерия Манна-Уитни U

$$U_1 = n_1 * n_2 + \{n_1 * (n_1 + 1) / 2\} - T_1$$

$$U_2 = n_1 * n_2 + \{n_2 * (n_2 + 1) / 2\} - T_2$$

$$U = \min(U_1, U_2)$$

$T_i$  — сумма рангов в объединенной выборке наблюдений из выборки  $i$

$n_1$  и  $n_2$  — размеры выборок

# Статистика критерия Манна-Уитни

## вариант объяснения идеи метода

Обозначим одну выборку  $x$ , другую  $y$ .

Для каждого наблюдения из выборки  $x$  сосчитаем число тех наблюдений в выборке  $y$ , которые меньше его. (пока считаем, что совпадений нет).

Сложим все полученные числа.

---

# Тогда причем тут медианы?

## Корректный ответ.


Дополнительные предположения

- Наблюдения случайных величин могут принимать любые значения в интервале
- Альтернативная гипотеза сдвига, т.е.


$$F_Y(t) = F_X(t + \Delta)$$

- Если критерий MWW отвергает гипотезу, то медианы различны
-

Гипотеза отвергается:  $p=0.0288$



Гипотеза не отвергается:  $p=0.46$



---

# Критерий Манна-Уитни-Вилкоксона в R

```
wilcox.test(x, y,  
            alternative = "two.sided",  
            paired = FALSE,  
            exact = TRUE,  
            correct = FALSE)
```

---

---

# Критерий Манна-Уитни-Вилкоксона в Python

`scipy.stats.mannwhitneyu`

`scipy.stats.wilcoxon`

---

---

# Примеры

- Время в магазинах
  - Альбукерк
  - Обучение менеджеров
-



# Еще раз, кратко

Если оба распределения несущественно отличаются от нормального, то используем критерий Стьюдента

Если сравниваем медианы, и много наблюдений, то используем критерий Муды

Если сравниваем медианы и распределения одинаковы по форме, то используем критерий Манна-Уитни

Если сравниваем медианы и распределения НЕ одинаковы по форме, иногда нельзя применять критерий Манна-Уитни,

```
x1 <- c( 1, 1, 1, 1000, 1000)
```

```
x2 <- c( 2, 3, 4, 5, 6)
```

Доходы x1 выше, x2 прибыльнее чаще