

Среднеквадратичная ошибка (MSE, mean square error) - часто используемый критерий качества. На чем он основывается, кроме здравого смысла и авторитета Карла Фридриха Гаусса?

Может ли MSE быть получен исходя из общих принципов?

Да может. Минимизация среднеквадратичной ошибки (MSE) - это не только неопределенно интуитивный подход, он может быть получен, используя метод максимального правдоподобия для случая линейной гауссовой модели.

Напоминание

Пусть X случайная величина с абсолютно непрерывным распределением.

Обозначим $f(t)$ плотность распределения случайной величины X .

Распределение известно с точностью до нескольких параметров, то есть плотность распределения может быть записана $f(t, a_1, a_2, \dots, a_k)$, где

a_1, a_2, \dots, a_k параметры, при этом какие бы значения ни приписать эти параметрам, функция $f(t, a_1, a_2, \dots, a_k)$ остается плотностью.

Известно n независимых наблюдений случайной величины X

$$x_1, x_2, x_3, \dots, x_n$$

В случае абсолютно непрерывного распределения мы не можем использовать то же самое определение, что и в случае дискретного распределения. Дело в том, что вероятность наблюдать именно те значения, которые были зарегистрированы равна нулю.

Вопрос 1 : Почему вероятность должна равняться нулю?

Определение функции правдоподобия для абсолютно непрерывного распределения.

Функция правдоподобия $L = f(x_1, x_2, x_3, \dots, x_n)$

где $f(t_1, t_2, t_3, \dots, t_n)$ - плотность совместного распределения случайных величин $X_1, X_2, X_3, \dots, X_n$

Если наблюдения случайной величины X независимые, то имеем

$$L = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n f(x_i, a_1, a_2, \dots, a_k)$$

Вопрос 2 : откуда появились n случайных величин?

Вопрос 3 : какие аргументы у функции L ?

Вопрос 4 : Использовалась независимость наблюдений. Сохраняется ли независимость после стандартизации?

Определение обыкновенной линейной регрессионной модели

Имеем вектор предикторов $\bar{X} = (X_1, X_2, X_3, \dots, X_k)$

Имеем отклик Y

Имеет вектор параметров $\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_k)^T$

Рассмотрим линейную модель

$$Y = \beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \dots + \beta_k \cdot X_k + \epsilon = .$$

$$.= \beta_0 \cdot X_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \dots + \beta_k \cdot X_k + \epsilon = X \cdot \beta + \epsilon$$

где ошибка $\epsilon \in N(0, \sigma^2)$. Предположим, что σ^2 известно, а ошибки независимы и одинаково распределены.

Пусть имеется набор данных. Вектор наблюдений отклика $\bar{Y} = (y_1, y_2, y_3, \dots, y_n)$ и таблица наблюдений предикторов X размерности $n \times k$.

Обозначим X_i i -ю строку таблицы X . Она содержит наблюдения предикторов для i -го наблюдения.

Обозначим e_i ошибку для i -го наблюдения.

Напомним, что правдоподобие - это вероятность наблюдать данные при фиксированных значениях параметров модели $\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_k)^T$

Доказательство

Выпишем лог правдоподобие для вектора наблюдений ошибок

$$\epsilon = Y - \beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \dots + \beta_k \cdot X_k = Y - \bar{X} \cdot \beta$$

Поскольку $\epsilon \in N(0, \sigma^2)$, плотность распределения ϵ имеет вид

$$\phi(t) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{t^2}{2\sigma^2}\right)$$

Выпишем лог-правдоподобие для ошибок модели

$$\begin{aligned} \log L &= \log p_Y(\bar{\epsilon}) = \log \prod_{i=1}^n \phi(\epsilon_i) = \sum_{i=1}^n \log \phi(\epsilon_i) = \\ &= \sum_{i=1}^n \log\left(\frac{1}{\sqrt{(2\pi\sigma^2)}} \cdot \exp\left(-\frac{(y_i - X_i \cdot \beta)^2}{2\sigma^2}\right)\right) = \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \sum_{i=1}^n \frac{(y_i - X_i \cdot \beta)^2}{2\sigma^2} = . \end{aligned}$$

Метод максимального правдоподобия предписывает нам выбрать в качестве параметров модели тот вектор $\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_k)^T$, для которого функция правдоподобия максимальна или лог правдоподобие максимально или - лог правдоподобие минимально

$$\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_k)^T = \operatorname{argmin}(-\log L) = .$$

$$.= \operatorname{argmin}\left(\frac{n}{2} \log(2\pi\sigma^2) + \sum_{i=1}^n \frac{(y_i - X_i \cdot \beta)^2}{2 \cdot \sigma^2}\right) = .$$

$$.= \operatorname{argmin}\left(\frac{1}{2 \cdot \sigma^2} \cdot \sum_{i=1}^n (y_i - X_i \cdot \beta)^2\right) = .$$

$$.= \operatorname{argmin}\left(\frac{1}{2 \cdot \sigma^2} \cdot \sum_{i=1}^n (y_i - X_i \cdot \beta)^2\right) = .$$

$$.= \operatorname{argmin}\left(\sum_{i=1}^n (y_i - X_i \cdot \beta)^2\right) = .$$

$$.= \operatorname{argmin}\left(\frac{1}{n} \cdot \sum_{i=1}^n (y_i - X_i \cdot \beta)^2\right) = MSE$$